

Asymptotic Efficiency in Estimation with Conditional Moment Restrictions

Chamberlain (1987)

Rafael Pereira Oliveira

Faculdade de Economia, Administração e Contabilidade (FEA-USP)

2026

Sumário

- 1 Questão central do artigo
- 2 O problema de restrições de momentos simples (seção 2)
- 3 O critério de eficiência: minimax local (seção 2.2)
- 4 Restrições de momentos condicionais (seção 4)
- 5 Como aproximar o limite com GMM? (seção 4.2)
- 6 Estrutura lógica do artigo (resumo esquemático)
- 7 Relevância para a econometria aplicada

1. Questão Central do Artigo

O artigo responde a uma pergunta fundamental em econometria semiparamétrica: qual é o menor limite inferior para a variância assintótica de um estimador consistente quando o que se sabe sobre a distribuição dos dados se expressa apenas por meio de restrições de momentos?

Em termos concretos, suponha que você tem dados i.i.d. e sabe que, para alguma função conhecida $g(\cdot)$,

$$E[g(z, \theta_0)] = 0 \tag{1}$$

mas não conhece a forma funcional da distribuição F_0 .

O estimador GMM de Hansen (1982) explora essas restrições, mas será que é possível fazer ainda melhor, usando algum estimador mais sofisticado?

1. Questão Central do Artigo

Chamberlain demonstra que não, desde que as restrições estejam na forma de momentos condicionais: o GMM, com o instrumento ótimo, é assintoticamente eficiente no sentido minimax local.

2. O Problema de Restrições de Momentos Simples (seção 2)

2.1 O setup

A forma geral de restrições de momentos é:

$$E[g(z, \theta_0)] = 0 \quad (2)$$

onde g é função conhecida, $\theta_0 \in \mathbb{R}^p$, e os dados são i.i.d. segundo distribuição desconhecida F_0 .

Hansen (1982) mostrou que o estimador GMM ótimo escolhe $\hat{\theta}$ para minimizar

$$\hat{g}(\theta)' \hat{W} \hat{g}(\theta) \quad (3)$$

com $\hat{W}$ convergindo para a matriz ótima, e tem variância assintótica igual a

$$A_0 = (G_0' \Omega_0^{-1} G_0)^{-1} \quad (4)$$

2. O Problema de Restrições de Momentos Simples (seção 2)

A pergunta é: A_0 é a variância ótima possível, ou existe algum estimador com variância menor?

2.2 A estratégia da aproximação multinomial

A jogada-chave do artigo é substituir o problema não-paramétrico por um paramétrico, usando distribuições multinomiais.

Ideia: suponha que z tem suporte finito com probabilidades $\pi_1, \dots, \pi_m$. Nesse caso, o problema se torna paramétrico: os parâmetros são as probabilidades sujeitas às restrições $E[g(z, \theta_0)] = 0$. A matriz de informação de Fisher fornece então o limite inferior da variância.

2. O Problema de Restrições de Momentos Simples (seção 2)

O Lema 2, resultado central da seção 2, mostra que a matriz de informação calculada para o caso multinomial é exatamente A_0 .

Portanto, saber que o suporte é finito e conhecido não melhora a eficiência assintótica em relação ao GMM ótimo.

Como qualquer F_0 pode ser aproximada arbitrariamente bem por uma multinomial, A_0 é também o limite para o caso geral.

3. O Critério de Eficiência: Minimax Local (seção 2.2)

Para que o argumento seja rigoroso, é preciso cuidado. Existem estimadores “supereficientes” que batem a cota da informação em pontos isolados do espaço paramétrico, mas se saem mal em vizinhanças desses pontos, Le Cam (1953).

Por isso, Chamberlain não usa o critério clássico de “menor variância para todo estimador consistente”, mas sim o critério de minimax local, que é mais geral e exclui esses casos patológicos.

3. O Critério de Eficiência: Minimax Local (seção 2.2)

O que é o critério de minimax local?

Define-se uma classe de funções de perda, simétricas, unimodais e com integrabilidade adequada. Para um estimador de θ_1 , primeiro componente do parâmetro, considera-se a perda esperada máxima em uma vizinhança encolhente de θ_0 :

$$\sup_{\theta \in \Theta_n(\theta_0)} E_{\theta} \left[L \left(\sqrt{n}(\hat{\theta}_1 - \theta_1) \right) \right] \quad (5)$$

O teorema de Hájek (1972), que embasa os resultados do artigo, assegura que para modelos que satisfazem a condição de normalidade assintótica local (LAN), esse limite inferior é o risco de um estimador normal com variância dada pelo elemento correspondente da matriz de informação.

3. O Critério de Eficiência: Minimax Local (seção 2.2)

Em particular, o limite inferior é

$$\int L(t) \phi(t; 0, I_{11}^{-1}) dt \quad (6)$$

onde I_{11}^{-1} é o elemento $(1, 1)$ de I^{-1} .

Isso significa que nenhum estimador pode ter, em uma vizinhança pequena de θ_0 , um risco esperado menor do que aquele de um estimador normal com variância I_{11}^{-1} .

3. O Critério de Eficiência: Minimax Local (seção 2.2)

Por que LAN importa?

A condição LAN diz que, em vizinhanças encolhendo na ordem $n^{-1/2}$, a razão de verossimilhanças é aproximadamente log-normal, o que torna a família paramétrica localmente “parecida com” um problema gaussiano.

Chamberlain verifica que a família multinomial construída no Lema 1 satisfaz LAN, o que garante a validade dos Teoremas 1 e 2.

O Teorema 2 é a versão do resultado para F_0 geral: para qualquer vizinhança de F_0 no espaço de distribuições, o limite inferior minimax local para a variância assintótica de qualquer estimador de θ_1 é A_0 .

4. Restrições de Momentos Condicionais (seção 4)

4.1 O setup

A parte mais relevante do artigo, e mais citada em IO e econometria aplicada, trata de restrições de momentos condicionais:

$$E[\rho(x, y, \theta_0) \mid x] = 0 \quad (7)$$

Esse tipo de restrição é muito mais forte do que $E[g(z, \theta_0)] = 0$: ela diz que o resíduo é ortogonal a qualquer função de x , não apenas a uma função específica.

4. Restrições de Momentos Condicionais (seção 4)

O exemplo canônico é o modelo de regressão linear

$$y = x'\theta_0 + u \quad (8)$$

no qual

$$\rho(x, y, \theta_0) = y - x'\theta_0 \quad (9)$$

Nesse caso, a restrição implica

$$E[h(x)\rho(x, y, \theta_0)] = 0 \quad (10)$$

para qualquer função $h(x)$, ou seja, há infinitas restrições de momentos.

4. Restrições de Momentos Condicionais (seção 4)

4.2 A variância ótima

Seguindo a mesma lógica de aproximação multinomial, mas agora aplicada às distribuições condicionais, Chamberlain deriva o limite inferior da variância assintótica para o caso condicional. O resultado é:

$$A_0^* = \{E[D_0(x)' \Sigma_0(x)^{-1} D_0(x)]\}^{-1} \quad (11)$$

onde:

- $D_0(x) = E\left[\frac{\partial \rho(x, y, \theta_0)}{\partial \theta} \middle| x\right]$ é a derivada esperada do resíduo condicional em θ_0 ;
- $\Sigma_0(x) = E[\rho(x, y, \theta_0)\rho(x, y, \theta_0)' | x]$ é a variância condicional do resíduo.

4. Restrições de Momentos Condicionais (seção 4)

Intuição: para o modelo de regressão $y = x'\theta_0 + u$, tem-se $D_0(x) = -x$ e $\Sigma_0(x) = \sigma^2(x)$, a variância condicional. Portanto:

$$A_0^* = \left\{ E \left[\frac{xx'}{\sigma^2(x)} \right] \right\}^{-1} \quad (12)$$

que é exatamente a variância assintótica do estimador de mínimos quadrados ponderados, WLS, que usa os pesos $1/\sigma^2(x)$.

Isso é intuitivo: se conhecêssemos a função de variância condicional, usaríamos WLS e seríamos eficientes; e de fato esse é o limite que não pode ser superado.

4. Restrições de Momentos Condicionais (seção 4)

4.3 O Teorema 3

O Teorema 3 formaliza esse resultado: sob a condição C_2 , versão da condição de regularidade para restrições condicionais, A_0^* é o limite minimax local para a variância assintótica de qualquer estimador consistente de θ_1 , mesmo que a distribuição condicional seja completamente desconhecida.

A prova usa o Lema 4 para construir, em qualquer vizinhança de F_0 , uma distribuição multinomial $\tilde{F}$ que compartilha os mesmos momentos condicionais relevantes, D_0 , Σ_0 , com F_0 , e então aplica os resultados das seções 2 e 3 à distribuição $\tilde{F}$.

5. Como Aproximar o Limite com GMM? (seção 4.2)

Saber que A_0^* é o limite é útil, mas Chamberlain vai além e mostra que o limite é atingível por uma sequência de estimadores GMM. A ideia é usar um conjunto crescente de instrumentos.

Construção: dado o modelo com restrição condicional $E[\rho(x, y, \theta_0) \mid x] = 0$, tome qualquer função $a(x)$, matriz de instrumentos, e defina

$$g(z, \theta) = a(x)\rho(x, y, \theta) \quad (13)$$

O estimador GMM baseado nessas restrições tem variância $A(a)$.

5. Como Aproximar o Limite com GMM? (seção 4.2)

Aumentando progressivamente a riqueza de $a(x)$, isto é, usando uma sequência $a_k(x)$ onde a_k é uma sequência linearmente independente e completa em $L^2(x)$, por exemplo, polinômios em x , a variância do GMM resultante satisfaz:

$$A_k \rightarrow A_0^* \quad (14)$$

(Proposição 2). No exemplo de regressão, usando $a_k(x)$ como polinômios em x , o GMM ótimo com esses instrumentos converge para o WLS ótimo à medida que $k \rightarrow \infty$.

5. Como Aproximar o Limite com GMM? (seção 4.2)

Uma ressalva importante que Chamberlain enfatiza: a Proposição 2 mostra $A_k \rightarrow A_0^*$ como propriedade dos limites assintóticos, para k fixo enquanto $n \rightarrow \infty$. Isso não é o mesmo que dizer que o estimador com k crescendo com a amostra tem distribuição limite A_0^* .

Esse segundo resultado, de convergência quando k cresce junto com n , é uma questão distinta e mais difícil, que Chamberlain deixa em aberto, mencionando trabalhos relacionados de Amemiya (1973), Sims (1974) e Hayashi e Sims (1983).

6. Estrutura Lógica do Artigo (Resumo Esquemático)

Pergunta: Qual é o limite inferior da variância assintótica em modelos não-paramétricos com restrições de momentos?

Passo 1: Caso multinomial (seção 2)

- Distribuição discreta com suporte finito conhecido
- Problema paramétrico $\rightarrow$ matriz de informação $\rightarrow$ Lema 2: variância $= A_0$

Passo 2: Caso geral com momentos incondicionais (seções 2–3)

- Qualquer F_0 pode ser aproximada por uma multinomial
- Teorema 2: A_0 é o limite minimax local para F_0 geral

6. Estrutura Lógica do Artigo (Resumo Esquemático)

Passo 3: Caso de momentos condicionais (seção 4)

- $E[\rho(x, y, \theta_0) \mid x] = 0 \rightarrow$ infinitas restrições de momentos
- Aproximação multinomial condicional (Lema 4)
- Teorema 3:

$$A_0^* = \{E[D_0' \Sigma_0^{-1} D_0]\}^{-1}$$

é o limite minimax local

Passo 4: Attainability (seção 4.2)

- Sequência de GMM com instrumentos polinomiais $\rightarrow A_k \rightarrow A_0^*$
- Proposição 2

7. Relevância para a Econometria Aplicada

O artigo tem impacto direto em várias áreas.

Variáveis instrumentais e GMM

O resultado legitima o uso do GMM ótimo como estimador eficiente em uma classe muito ampla de modelos, sem assumir normalidade ou homocedasticidade. A variância ótima justifica o uso de WLS ou IV com matriz de ponderação ótima.

IO estrutural (BLP, Berry-Rand)

Modelos de demanda com instrumentos usam implicitamente restrições da forma $E[\xi_j | z_j] = 0$. A cota de Chamberlain diz que, dado o conjunto de instrumentos, o GMM ótimo não pode ser superado sem assumir mais estrutura distributiva.

7. Relevância para a Econometria Aplicada

Eficiência semiparamétrica

O paper é uma das pedras fundadoras da literatura de eficiência semiparamétrica, ao lado de trabalhos de Begun, Hall, Huang e Wellner (1983) e da teoria de *tangent spaces*. A ideia de usar distribuições multinomiais como aproximações para provar cotas não-paramétricas se tornou uma técnica padrão nessa literatura.

Escolha de instrumentos

A Proposição 2 formaliza a intuição de que “mais instrumentos é melhor” no sentido assintótico, desde que se use a ponderação ótima. Na prática, porém, há um *trade-off* com o viés em amostras finitas, que o artigo não aborda.

Obrigado

Obrigado!