

Measuring Substitution Patterns in Differentiated-Products Industries

Gandhi e Houde (2019)

Rafael Pereira Oliveira

Faculdade de Economia, Administração e Contabilidade (FEA-USP)

2019

Sumário

- 1 Motivação e Problema de Pesquisa
- 2 Revisão da Literatura e Contribuição
- 3 Arcabouço Teórico e Modelo de Demanda
- 4 Identificação e o Problema de Instrumentos Fracos
- 5 Proposições Centrais: Forma Reduzida como Função Simétrica
- 6 Instrumentos de Diferenciação (*Differentiation IVs*)
- 7 Implicações Adicionais: IV Ótimo, Estimação Não-Paramétrica e Teste IIA
- 8 Simulações de Monte Carlo
- 9 Aplicação: Demanda por Automóveis
- 10 Limitações, Extensões e Legado

Motivação e Problema de Pesquisa

- Modelos de demanda por produtos diferenciados são essenciais para política antitruste, regulação e análise de bem-estar
- A abordagem dominante — o modelo BLP (Berry, Levinsohn e Pakes, 1995) — estima coeficientes aleatórios via GMM não-linear com dados agregados de participação de mercado
- **Problema central:** os instrumentos tradicionais do BLP frequentemente falham em identificar padrões de substituição, gerando estimativas imprecisas dos coeficientes de heterogeneidade

Questão de pesquisa

Por que os instrumentos usuais do BLP são fracos? Quais instrumentos alternativos resolvem esse problema?

Motivação e Problema de Pesquisa (cont.)

- Com instrumentos fracos: GMM não-linear produz RMSEs elevados, mínimos locais e soluções de canto ($\hat{\lambda} \rightarrow 0$, colapsando ao logit simples)
- Estimativas ruins de λ implicam padrões de substituição errados — fundamentais para simulações de fusão e cálculo de margem
- Os autores propõem novos instrumentos baseados na **distribuição de diferenças de características** entre produtos rivais
- Contribuição: fundamentação teórica (por que esses IVs identificam λ) + evidência empírica de sua superioridade

Revisão da Literatura e Contribuição

- **Berry (1994)**: inversão da demanda com dados agregados — base para estimação GMM
- **BLP (1995)**: coeficientes aleatórios para capturar heterogeneidade; instrumentos de soma de características rivais (*Sum IVs*)
- **Nevo (2001)**: instrumentos baseados em características de produtos em outros mercados (*Hausman-style*)
- **Reynaert e Verboven (2014)**: primeiros a documentar fraqueza dos instrumentos BLP clássicos em simulações

Contribuição de Gandhi e Houde

Derivação formal de por que os IVs tradicionais são fracos + proposta de *Differentiation IVs* com fundamento teórico na forma reduzida da demanda

Revisão da Literatura e Contribuição (cont.)

- **Problema dos Sum IVs:** somam características de rivais sem capturar a *distribuição* dessas diferenças — informação insuficiente para identificar λ
- Conexão com literatura de variáveis instrumentais ótimas: Chamberlain (1987), Newey (1990) — o IV ótimo é a derivada esperada do momento em relação aos parâmetros
- Literatura de mercados com substituição local: Pinkse, Slade e Brett (2002); Petrin (2002)
- Gandhi e Houde unificam a lógica de identificação com a estrutura do modelo BLP, tornando os resultados diretamente aplicáveis a qualquer estimação de demanda com dados agregados

Arcabouço Teórico e Modelo de Demanda

- Mercados $t = 1, \dots, T$; produtos $j = 1, \dots, J_t$; consumidores $i = 1, \dots, N_t$
- Utilidade indireta do consumidor i pelo produto j no mercado t :

$$u_{ijt} = x'_{jt}\beta_i - \alpha_i p_{jt} + \xi_{jt} + \varepsilon_{ijt} \quad (1)$$

- x_{jt} : vetor de características observáveis; p_{jt} : preço; ξ_{jt} : inobservável; $\varepsilon_{ijt} \sim$ Tipo I VE
- Coeficientes aleatórios: $(\beta_i, \alpha_i) = (\bar{\beta}, \bar{\alpha}) + \Pi \nu_i$, com $\nu_i \sim F(\nu; \lambda)$

Intuição

Heterogeneidade nos gostos (λ) gera substituição não-proporcional entre produtos com características similares — o que o logit simples não captura

Arcabouço Teórico e Modelo de Demanda (cont.)

- Participação de mercado do produto j :

$$s_{jt}(x_t, p_t, \xi_t; \lambda) = \int \frac{\exp(x'_{jt}\beta_i - \alpha_i p_{jt} + \xi_{jt})}{1 + \sum_k \exp(x'_{kt}\beta_i - \alpha_i p_{kt} + \xi_{kt})} dF(\nu_i; \lambda) \quad (2)$$

- Condições de momentos GMM: $\mathbb{E}[\xi_{jt}(\lambda) \cdot z_{jt}] = 0$, onde $\xi_{jt}(\lambda) = \sigma_{jt}^{-1}(s_t; \lambda) - x'_{jt}\beta$
- **Hipótese de exclusão**: instrumentos z_{jt} não correlacionados com ξ_{jt}
- Estimação por Mínimos Quadrados Generalizados Iterativos (GMR — Gauss-Newton Regression)

Identificação e o Problema de Instrumentos Fracos

- **Premissa:** λ só é identificado se os IVs geram variação suficiente nos momentos $\mathbb{E}[\xi_{jt}(\lambda) \cdot z_{jt}]$ ao redor do valor verdadeiro λ_0
- Com $\lambda \rightarrow 0$ (logit): $\sigma_{jt}^{-1}(s_t; \lambda) \approx \ln s_{jt} - \ln s_{0t}$ — IVs não precisam de informação sobre rivalidade
- IVs fracos falham em rejeitar $H_0 : \lambda = 0$ — modelo colapsa ao logit com IIA (*Independence of Irrelevant Alternatives*)

IIA e problema de identificação

Sob IIA, todos os produtos competem igualmente — o instrumento não precisa capturar quem é rival próximo. Identificar $\lambda \neq 0$ requer IVs que reflitam a *localização* dos rivais no espaço de características

Identificação e o Problema de Instrumentos Fracos (cont.)

- **Sum IVs** (BLP clássico): $z_{jt}^{sum,k} = \sum_{l \neq j} x_{kt}^l$ — soma de características dos rivais
- Problema: a soma é insensível à *distribuição* das diferenças de características — dois produtos podem ter a mesma soma com distribuições completamente distintas
- Consequências empíricas documentadas: RMSEs muito elevados; múltiplos mínimos locais na função objetivo; estimativas de λ concentradas em zero
- **Solução proposta**: instrumentos baseados em $d_{jt,k} = x_{kt}^l - x_{kt}^j$ — diferenças de características de cada rival em relação a j

Proposições Centrais: Forma Reduzida como Função Simétrica

- **Proposição 1 — Demanda inversa:** Sob as Suposições 1–3 do modelo,

$$\sigma_{jt}^{-1}(s_t; \lambda) = f(\omega_{jt}; \lambda) + C_t(\lambda) \quad (3)$$

- $\omega_{jt} = \{d_{jt,k}^l\}_{l \neq j,k}$: conjunto de diferenças de características de j em relação a todos os rivais
- $f(\cdot)$: função simétrica nas diferenças — intercambiabilidade dos rivais
- $C_t(\lambda)$: constante de mercado, absorvida por efeito fixo de mercado
- **Intuição:** a demanda inversa de j depende apenas de *quão diferente* j é dos rivais, não de suas características em nível

Proposições Centrais: Forma Reduzida como Função Simétrica (cont.)

- **Proposição 2 — Forma reduzida de preços:** O preço reduzido satisfaz

$$\pi_{jt}(x_t; \lambda) = g(d_{jt}; \lambda) + c_t(\lambda) \quad (4)$$

- $g(\cdot)$: função simétrica nas diferenças d_{jt} — mesma estrutura da demanda inversa
- **Implicação:** a forma reduzida depende apenas das diferenças, não das características em nível dos rivais
- Quebra a “maldição da dimensionalidade”: em vez de condicionar em x_t inteiro ($J_t \times K$ dimensões), basta condicionar em d_{jt} (K dimensões de diferenças por produto)
- Isso motiva diretamente os *Differentiation IVs*: funções de d_{jt} são válidas e relevantes por construção

Instrumentos de Diferenciação (*Differentiation IVs*)

- Derivados diretamente das Proposições 1 e 2: IVs devem ser funções das diferenças de características $d_{jt,k}^l = x_{kt}^l - x_{kt}^j$
- Differentiation IV Quadrático** (captura dispersão dos rivais):

$$z_{jt,k}^{quad} = \sum_{l \neq j} \left(x_{kt}^l - x_{kt}^j \right)^2 \quad (5)$$

- Soma dos quadrados das diferenças em característica k — maior valor indica que j está mais isolado no espaço de características
- Differentiation IV Local** (captura rivalidade próxima):

$$z_{jt,k}^{local} = \sum_{l \neq j} \mathbf{1} \left(|x_{kt}^l - x_{kt}^j| < sd_k \right) \quad (6)$$

Instrumentos de Diferenciação (cont.)

- IV Local: conta o número de rivais com características próximas (dentro de 1 desvio-padrão) — proxy direta para concorrência local
- **Validade:** IVs são funções de x_{kt}^l (características dos rivais), excluídas da equação de demanda de j sob hipótese de exogeneidade das características
- **Relevância:** por Proposição 2, a forma reduzida é função de d_{jt} , logo qualquer função de d_{jt} é correlacionada com $\xi_{jt}(\lambda)$ quando $\lambda \neq 0$
- IVs podem ser empilhados em vetor: $z_{jt} = (z_{jt,1}^{quad}, \dots, z_{jt,K}^{quad}, z_{jt,1}^{local}, \dots, z_{jt,K}^{local})$

Comparação com Sum IVs

Sum IVs capturam apenas a média dos rivais; Differentiation IVs capturam a *distribuição* — informação muito mais rica para identificar heterogeneidade

IV Ótimo e Estimação Não-Paramétrica

- **IV Ótimo** (Chamberlain 1987; Newey 1990): minimiza variância assintótica do estimador GMM
- Para o modelo BLP, o IV ótimo é:

$$z_{jt}^* = \mathbb{E} \left[\frac{\partial \xi_{jt}(\lambda_0)}{\partial \lambda} \middle| x_t \right] \quad (7)$$

- Por Proposição 2: z_{jt}^* é função de d_{jt} — confirma que Differentiation IVs são aproximações do IV ótimo
- **Estimação não-paramétrica**: aproximar z_{jt}^* por séries de polinômios em d_{jt} sem especificar forma funcional
- Benefício: não requer conhecer $F(\nu; \lambda)$ para construir o IV — procedimento robusto à especificação

Teste de Independência de Alternativas Irrelevantes (IIA)

- **Hipótese IIA:** sob logit simples ($\lambda = 0$), a razão de participações não depende da presença de outros produtos
- O artigo propõe um teste formal de IIA baseado nos Differentiation IVs:

$$\ln(s_{jt}/s_{0t}) = x'_{jt}\beta + \gamma_1 z_{jt}^{sum} + \gamma_2 z_{jt}^{diff} + \varepsilon_{jt} \quad (8)$$

- $H_0 : \gamma_2 = 0$ — IVs de diferenciação não têm poder explicativo adicional além dos Sum IVs
- Rejeição de H_0 indica que os Differentiation IVs são instrumentos fortes — heterogeneidade identificável
- **Interpretação:** se IIA não vale, a localização relativa dos produtos importa para a demanda, e os Diff IVs capturam isso

Simulações de Monte Carlo — Desenho

- Ambiente simulado: $T = 50$ mercados, $J = 25$ produtos por mercado, $K = 2$ características (x_1, x_2) distribuídas uniformemente
- Parâmetro verdadeiro de heterogeneidade: $\lambda_0 = 1$
- Cinco cenários de instrumentos comparados:
 - 1 **Sum IV**: instrumento BLP clássico ($\sum_{l \neq j} x_k^l$)
 - 2 **Diff IV Quadrático**: $\sum_{l \neq j} (x_k^l - x_k^j)^2$
 - 3 **Diff IV Local**: $\sum_{l \neq j} \mathbf{1}(|x_k^l - x_k^j| < sd_k)$
 - 4 **IV Ótimo Não-Paramétrico**: séries em d_{jt}
 - 5 **IV Ótimo Paramétrico**: derivada analítica (benchmark)

Simulações de Monte Carlo — Resultados

- Critério de avaliação: RMSE de $\hat{\lambda}$, frequência de mínimos locais e frequência de soluções de canto ($\hat{\lambda} < 0.01$)

Instrumento	RMSE	Mínimos Locais (%)	Soluções de Canto (%)	Rejeição IIA (%)
Sum IV	0.85	42	38	8
Diff IV Quadrático	0.05	0	0	97
Diff IV Local	0.04	0	0	98
IV Ótimo Não-Param.	0.03	0	0	99
IV Ótimo Paramétrico	0.02	0	0	100

- Differentiation IVs reduzem o RMSE em $\approx 17\times$ em relação ao Sum IV
- Eliminam completamente mínimos locais e soluções de canto

Simulações de Monte Carlo — Interpretação

- **Por que Sum IV falha?** Dois mercados com mesma soma de características podem ter distribuições de rivalidade completamente distintas — o instrumento não discrimina entre eles
- **Por que Diff IVs funcionam?** Capturam a variação na distribuição de d_{jt} — quando $\lambda \neq 0$, essa distribuição é diretamente mapeada na demanda inversa
- **IV Local vs. Quadrático:** ambos têm desempenho similar; Local é mais intuitivo (conta vizinhos próximos); Quadrático é mais fácil de computar
- **IV Ótimo Não-Paramétrico:** desempenho próximo ao paramétrico — confirmação de que séries em d_{jt} aproximam bem o IV ótimo

Aplicação: Demanda por Automóveis — Dados

- Base: dados BLP originais de automóveis dos EUA, 1971–1990 (2.217 observações produto-mercado)
- Variáveis de características: preço, número de portas, ar-condicionado, potência, tamanho
- Três coeficientes aleatórios estimados: preço (α_i), número de portas (β_i^{doors}), ar-condicionado (β_i^{air})
- IVs utilizados: Differentiation IVs Quadrático e Local para cada característica com coeficiente aleatório

Comparação com BLP (1995)

Mesmos dados e estrutura de modelo — permite comparação direta dos resultados com e sem Differentiation IVs

Aplicação: Demanda por Automóveis — Resultados

- **Elasticidades preço próprias:** mediana de -1.2 (BLP clássico: -3.0 a -6.0 , muito elevadas)
- **Heterogeneidade estimada:** coeficientes aleatórios significativamente diferentes de zero para preço e ar-condicionado
- Sum IVs produzem $\hat{\lambda} \approx 0$ para portas — colapso ao logit; Diff IVs identificam heterogeneidade significativa
- **Padrões de substituição:** com Diff IVs, produtos similares substituem-se mais entre si — resultado economicamente plausível

Teste IIA na aplicação

Fortemente rejeitado ($p < 0.001$) para os três coeficientes aleatórios — Diff IVs são instrumentos fortes nos dados reais

Aplicação: Demanda por Automóveis — Implicações

- Elasticidades mais baixas (em módulo) com Diff IVs implicam **margens de Lerner maiores** — consistente com evidência de rentabilidade da indústria automotiva
- Padrões de substituição precisos são cruciais para: análise de fusão (unilateral effects), simulação de pricing pós-fusão, avaliação de inovação de produto
- **Resultado de política:** uso de Sum IVs tende a superestimar elasticidades e subestimar poder de mercado — viés com implicações para análise antitruste
- Resultados são robustos a diferentes especificações de coeficientes aleatórios e diferentes conjuntos de IVs baseados em diferenças

Limitações, Extensões e Legado

- **Limitações:** resultados baseados em características observáveis — se há características latentes relevantes, as diferenças d_{jt} podem não capturar toda a rivalidade relevante
- Suposição de Intercambiabilidade (Assumption 3): identidade dos rivais não importa além das diferenças de características — restritiva em mercados com forte diferenciação vertical
- Dados agregados: sem dados individuais de compra, a heterogeneidade só é identificada através da variação entre mercados

Extensões naturais

- IV Ótimo com características latentes (combinação com micro-dados)
- Extensão para modelos de oferta com conduct parameters

Legado e Impacto

- **Adoção na prática:** Differentiation IVs tornaram-se instrumentos padrão em estimações BLP — implementados em pacotes como PyBLP (Conlon e Gortmaker, 2020)
- **Impacto metodológico:** artigo demonstra que a escolha de IVs em modelos não-lineares não é arbitrária — má escolha invalida inferência sobre parâmetros-chave
- **Resultado teórico durável:** conexão entre a estrutura de substituição local no espaço de características e a identificação de λ — válida além do modelo BLP específico
- **Implicação para pesquisa empírica:** antes de interpretar estimativas BLP, verificar fortaleza dos IVs via teste IIA proposto no artigo

Obrigado

Obrigado!