

Improving the Performance of Random Coefficients Demand Models: the Role of Optimal Instruments

Reynaert e Verboven (2012)

Rafael Pereira Oliveira

Faculdade de Economia, Administração e Contabilidade (FEA-USP)

2012

Sumário

- 1 Motivação e Problema de Pesquisa
- 2 Revisão da Literatura e Contribuição
- 3 O Modelo: Demanda com Coeficientes Aleatórios
- 4 O Estimador GMM e Estratégia de Identificação
- 5 Instrumentos Ótimos de Chamberlain (1987)
- 6 Processo Gerador de Dados e Detalhes Computacionais
- 7 Viés e Eficiência: Instrumentos Padrão vs. Ótimos
- 8 Instrumentos Fracos para Preço e Desempenho com Amostra
- 9 Desempenho Computacional: MPEC, Integração e Mínimos Locais
- 10 Conclusão e Avisos Cautelares

Motivação e Problema de Pesquisa

- O modelo logit de coeficientes aleatórios de Berry, Levinsohn e Pakes (1995) — BLP — é a principal ferramenta para estimar demanda por produtos diferenciados com dados agregados
- Captura heterogeneidade não observada nas preferências via coeficientes aleatórios σ^k sobre as características, gerando padrões de substituição flexíveis
- Apesar de avanços recentes (MPEC, integração polinomial, algoritmos aprimorados), o estimador GMM frequentemente apresenta viés, imprecisão e instabilidade numérica

Hipótese central

Os problemas decorrem do uso de instrumentos inefficientes. Os instrumentos ótimos de Chamberlain (1987) resolvem simultaneamente viés, eficiência e estabilidade do estimador GMM do modelo BLP.

Problemas documentados com o estimador BLP:

- **Knittel e Metaxoglou (2012):** convergência global comprometida; estimativas muito sensíveis a valores iniciais
- **Dubé, Fox e Su (2012):** NFP propaga erros numéricos do loop interno; propõem MPEC como alternativa mais rápida
- **Skrainka e Judd (2011):** integração pMC imprecisa; integração Sparse Grid é superior
- **Armstrong (2012):** instrumentos BLP são fracos para o preço; recomendam cost shifters

Revisão da Literatura e Contribuição (cont.)

Contribuição de Reynaert e Verboven (2012)

- Identificam o problema fundamental: instrumentos ineficientes para identificar σ (variâncias dos coeficientes aleatórios)
- Instrumentos ótimos de Chamberlain (1987) resolvem viés, eficiência e estabilidade simultaneamente
- MPEC e integração Sparse Grid só produzem ganhos consistentes quando combinados com instrumentos ótimos

Comparação com outros trabalhos:

- Armstrong (2012) foca instrumentos para α (preço); Reynaert e Verboven focam instrumentos para σ (heterogeneidade) — contribuições complementares
- Abordagem bayesiana (Jiang et al., 2009) também produz estimativas mais precisas, mas é mais lenta e exige suposições mais fortes

O Modelo: Utilidade e Coeficientes Aleatórios

Utilidade indireta condicional do consumidor i pelo produto j no mercado t :

$$u_{ijt} = x_{jt}\beta_i - \alpha p_{jt} + \xi_{jt} + \varepsilon_{ijt} \quad (1)$$

- x_{jt} : características observáveis; p_{jt} : preço; ξ_{jt} : inobservável de demanda
- α : utilidade marginal da renda (homogênea); ε_{ijt} : choque i.i.d. tipo I valor extremo
- Coeficiente aleatório: $\beta_i^k = \beta^k + \sigma^k \nu_i^k$, com $\nu_i^k \sim (0, 1)$

Decomposição em utilidade média e heterogeneidade individual:

$$u_{ijt} = \underbrace{\delta_{jt}}_{\text{utilidade média}} + \underbrace{\mu_{jt}(\nu_i)}_{\text{heterog. individual}} + \varepsilon_{ijt} \quad (2)$$

onde $\delta_{jt} \equiv x_{jt}\beta - \alpha p_{jt} + \xi_{jt}$ e $\mu_{jt}(\nu_i) \equiv \sum_k x_{jt}^k \sigma^k \nu_i^k$.

O Modelo: Quotas de Mercado e Lado da Oferta

Quota de mercado predita (integral sobre a heterogeneidade dos consumidores):

$$s_{jt}(\delta_t, \sigma) = \int \frac{\exp(\delta_{jt} + \mu_{jt}(\nu))}{1 + \sum_{l=1}^J \exp(\delta_{lt} + \mu_{lt}(\nu))} dP_\nu(\nu) \quad (3)$$

- Integração pseudo-Monte Carlo (pMC): $s_{jt} \approx \frac{1}{m} \sum_{i=1}^m [\dots]$ — rápida mas imprecisa
- Integração Sparse Grid: $s_{jt} \approx \sum_{i=1}^n \phi_i[\dots]$ — mais precisa e, com instrumentos ótimos, mais rápida

Lado da oferta (competição perfeita):

$$p_t = X_t \gamma_1 + W_t \gamma_2 + \omega_t \quad (4)$$

Os cost shifters W_t afetam apenas o custo — servem como instrumentos para o preço endógeno.

O Estimador GMM e Estratégia de Identificação

Restrição de momento central:

$$E[\xi_{jt} \mid X_t, w_{jt}] = 0 \Rightarrow E[\xi_{jt} z_{jt}] = 0 \quad (5)$$

- ξ_{jt} é independente em média das características de todos os produtos e dos cost shifters
- GMM minimiza: $\min_{\theta} \xi(\theta)' ZAZ' \xi(\theta)$

Dois algoritmos de estimação:

- **NFP (BLP):** loop externo minimiza GMM; loop interno inverte $s_t(\delta_t, \sigma) = s_t$ por mapeamento de contração — erros do loop interno propagam para o externo
- **MPEC (Dubé et al., 2012):** $\min_{\theta, \xi} \xi' ZAZ' \xi$ sujeito a $s(\delta, \sigma) = s$ — elimina o loop interno; equivalente ao NFP em teoria, mais rápido na prática

Instrumentos Ótimos de Chamberlain (1987) — Teoria

Três conjuntos de instrumentos padrão:

- $z_{jt}^1 = (x_{jt}, w_{jt})$: características e cost shifters
- z_{jt}^2 : z_{jt}^1 + polinômios (quadrados e interações de x_{jt} e w_{jt})
- z_{jt}^3 : z_{jt}^1 + somas de características dos concorrentes $\sum_{k \neq j} x_{kt}$ (instrumentos BLP)

Instrumentos ótimos de Chamberlain (1987) — máxima eficiência assintótica:

$$z_{jt} = E \left[\frac{\partial \xi_{jt}(\theta)}{\partial \theta'} \mid X_t, w_{jt} \right] \quad (6)$$

Exploram a estrutura funcional do modelo para minimizar a variância assintótica do estimador GMM.

Instrumentos Ótimos — Parâmetros Lineares e Não Lineares

Para parâmetros lineares β e α (interpretação 2SLS):

$$E\left[\frac{\partial \xi_{jt}}{\partial \beta'}\right] = x_{jt}, \quad E\left[\frac{\partial \xi_{jt}}{\partial \alpha}\right] = x_{jt}\gamma_1 + w_{jt}\gamma_2 \quad (7)$$

- Instrumento para β : os próprios regressores x_{jt}
- Instrumento para α : preço predito da 1ª etapa (OLS sobre cost shifters) — idêntico ao 2SLS linear; não depende dos parâmetros de demanda

Para parâmetros não lineares σ (infeasíveis — requerem 1ª etapa):

$$E\left[\frac{\partial \xi_{jt}(\theta)}{\partial \sigma'} \mid X_t, w_{jt}\right] = E\left[\frac{\partial \delta_{jt}(s_t, \sigma)}{\partial \sigma'} \mid X_t, w_{jt}\right] \quad (8)$$

Função não linear das características de todos os concorrentes; captura como δ_{jt} varia com a heterogeneidade σ .

Implementação dos Instrumentos Ótimos para σ

Implementação aproximada (z_{jt}^4 — BLP, 1999):

- 1 Obter estimativa inicial $\hat{\theta} = (\hat{\beta}, \hat{\alpha}, \hat{\sigma})$ usando z^1
- 2 Calcular preço predito $\hat{p}_t = X_t \hat{\gamma}_1 + W_t \hat{\gamma}_2$
- 3 Calcular $\hat{\delta}_t = X_t \hat{\beta} - \hat{\alpha} \hat{p}_t$ e quotas $\hat{s}_t = s_t(\hat{\delta}_t, \hat{\sigma})$
- 4 Usar o Jacobiano $\partial \delta_t(\hat{s}_t, \sigma) / \partial \sigma' |_{\sigma=\hat{\sigma}}$ como instrumento

Implementação exata (z_{jt}^5): média do Jacobiano sobre K simulações de $\hat{\xi}_t$:

$$\frac{1}{K} \sum_{k=1}^K \left. \frac{\partial \delta_t(\hat{s}_t^k, \sigma)}{\partial \sigma'} \right|_{\sigma=\hat{\sigma}} \quad (9)$$

Resultado prático crucial: 1ª etapa com logit simples ($\sigma = 0$) e chute inicial para $\hat{\sigma}^1$ é suficiente — evita estimação custosa do modelo completo de coeficientes aleatórios.

Processo Gerador de Dados e Detalhes Computacionais

Design Monte Carlo: 1.000 conjuntos de dados; $T = 25$ mercados, $J = 10$ produtos.

- $x_{jt} = (1, x_{jt}^1)$, com $x_{jt}^1 \sim U(1, 2)$; cost shifters $w_{jt} \sim U(0, 1)^3$
- $(\xi_{jt}, \omega_{jt}) \sim N\left(\mathbf{0}, \begin{bmatrix} 1 & 0,7 \\ 0,7 & 1 \end{bmatrix}\right)$

Parâmetros verdadeiros: $\beta = (2, 2)$, $\alpha = -2$, $\sigma = (0, 1)$; $\gamma_2 = (3, 3, 3)$ (instrumentos fortes para preço). **Detalhes computacionais:**

- Knitro 800 Interior\Direct (Matlab); MPEC com Jacobiano e Hessiana analíticos
- 10 valores iniciais por dataset; seleciona menor valor da função objetivo
- Sparse Grid com 9 nós (exata para polinômios até grau 17)

Resultados com Instrumentos Padrão — Tabela 1

Parâmetro	Verdadeiro	z_{jt}^1		z_{jt}^2		z_{jt}^3	
		Viés	RMSE	Viés	RMSE	Viés	RMSE
β^0	2	0,295	1,739	-0,087	0,787	0,115	1,175
β^1	2	-0,291	1,584	0,032	0,617	-0,119	1,097
α	-2	-0,028	0,137	0,007	0,053	-0,009	0,075
σ^1	1	0,088	1,316	-0,100	0,549	0,011	0,817

- RMSE muito elevado para β e σ^1 ; apenas α é estimado com precisão (cost shifters fortes para o preço)
- $\sim 30\%$ das estimativas de σ^1 colapsa para zero com z^1 ; $\sim 15\%$ com z^2 e z^3

Resultados com Instrumentos Ótimos — Tabela 2

Parâmetro	Verdadeiro	z_{jt}^4 (aproximado)		z_{jt}^5 (exato)	
		Viés	RMSE	Viés	RMSE
β^0	2	0,000	0,466	-0,003	0,446
β^1	2	-0,003	0,328	0,001	0,278
α	-2	-0,001	0,042	-0,0004	0,042
σ^1	1	-0,001	0,192	-0,003	0,142

- Viés reduzido por fator > 10 vs. melhor instrumento padrão (z^2)
- RMSE de σ^1 : cai de 1,316 (z^1) / 0,549 (z^2) para 0,192 (z^4) e 0,142 (z^5)
- Pico em zero desaparece; distribuição fortemente concentrada ao redor do valor verdadeiro

1ª Etapa com Logit Simples — Tabela 3

- Substituindo a 1ª etapa (coeficientes aleatórios) por um logit simples com chute inicial para $\hat{\sigma}^1$, os resultados são quase idênticos:

Parâmetro	Verdadeiro	z_{jt}^4 (1ª etapa: logit)		z_{jt}^5 (1ª etapa: logit)	
		Viés	RMSE	Viés	RMSE
β^0	2	-0,003	0,447	-0,003	0,445
β^1	2	0,000	0,280	0,001	0,278
α	-2	0,000	0,042	0,000	0,042
σ^1	1	-0,002	0,143	-0,002	0,139

- Implicação prática: não é necessário estimar o modelo completo de coeficientes aleatórios na 1ª etapa

Instrumentos Fracos para Preço — Tabela 4

Cenário: $\gamma_2 = (0,3; 0,3; 0,3)$ — cost shifters têm impacto fraco nos preços

Parâmetro	Verdadeiro	z_{jt}^1 (padrão)		z_{jt}^4 (ótimo)	
		Viés	RMSE	Viés	RMSE
β^0	2	1,052	3,834	-0,032	1,500
β^1	2	0,041	0,664	-0,111	0,404
α	-2	0,098	0,533	0,165	0,441
σ^1	1	0,457	2,185	0,033	0,760

- $RMSE(\sigma^1)$ cai de 2,185 (z^1) para 0,760 (z^4) — redução de $\approx 65\%$
- Ganhos para σ são independentes da qualidade dos instrumentos de preço

Desempenho com Tamanho de Amostra — Tabela 5

Com instrumentos ótimos (z^4), RMSE melhora na ordem de $\sqrt{J}$ e $\sqrt{T}$:

Parâm.	Verd.	Variando J ($T = 25$)			Variando T ($J = 10$)		
		$J = 5$	$J = 10$	$J = 20$	$T = 12$	$T = 25$	$T = 50$
β^0	2	0,647	0,447	0,315	0,700	0,447	0,308
β^1	2	0,446	0,280	0,191	0,476	0,280	0,194
α	-2	0,065	0,042	0,031	0,065	0,042	0,031
σ^1	1	0,223	0,143	0,124	0,276	0,143	0,095

- Contraste: com instrumentos padrão, Skrainka (2012) documenta que o RMSE *não* melhora com o tamanho da amostra — o problema é a qualidade dos instrumentos, não o tamanho amostral

MPEC versus NFP — Tabela 6

- Com instrumentos ótimos: MPEC é $\approx 10\times$ mais rápido que NFP
- Com instrumentos padrão: MPEC é apenas $\approx 1,75\times$ mais rápido

	NFP		MPEC	
	z_{jt}^1	z_{jt}^4	z_{jt}^1	z_{jt}^4
CPU médio (seg)	37,64	90,63	21,53	9,31
RMSE(σ^1)	1,208	0,143	1,316	0,143

- Com z^4 : NFP e MPEC dão resultados idênticos — confirma equivalência teórica (Su e Judd, 2012)
- Com z^1 : divergem mesmo com critério de convergência 10^{-12} no loop interno

Integração Numérica: pMC versus Sparse Grid — Tabela 7

Método	Precisão	CPU (seg)	Viés(σ^1)	RMSE(σ^1)
pMC	200 draws	41,44	-0,089	0,249
pMC	100 draws	29,18	-0,147	0,299
pMC	50 draws	17,89	-0,236	0,361
Sparse Grid	19 nós	12,47	-0,004	0,143
Sparse Grid	9 nós	8,00	-0,004	0,143
Sparse Grid	7 nós	6,43	-0,004	0,139

- Sparse Grid é simultaneamente mais rápida e mais precisa que pMC com instrumentos ótimos
- RMSE insensível ao número de nós acima de 7 — patamar de precisão atingido rapidamente
- Com instrumentos padrão: Skrainka e Judd (2011) não encontram vantagens claras de Sparse Grid em viés/RMSE

Mínimos Locais e Sensibilidade a Valores Iniciais — Tabela 8

Desvio-padrão das estimativas sob 10 valores iniciais (média sobre 50 datasets):

Parâmetro	z_{jt}^1 (Desv.-Pad.)	z_{jt}^4 (Desv.-Pad.)
β^0	0,117	0,028
β^1	0,140	0,024
α	0,007	0,001
σ^1	0,108	0,019
Valor da função objetivo	0,029	$1,07 \times 10^{-13}$

- Com z^4 : desvios-padrão $\approx 5\times$ menores; convergência em 100% dos casos (vs. 37 não-convergências com z^1)
- A não linearidade inerente do modelo ainda justifica múltiplos valores iniciais mesmo com z^4

Conclusão

Os instrumentos ótimos de Chamberlain (1987) resolvem os principais problemas do estimador GMM do modelo BLP:

- **Viés:** reduzido por fator > 10 para σ^1 vs. melhor instrumento padrão
- **Eficiência:** $RMSE(\sigma^1)$ cai de $\approx 1,3$ para $\approx 0,14$ — redução de $\approx 90\%$
- **Estabilidade:** $\approx 5\times$ menos variação entre valores iniciais; zero não-convergências
- **Melhoria com amostra:** RMSE decresce na ordem $\sqrt{J}$ e $\sqrt{T}$ (não ocorre com padrão)

Recomendação prática: buscar cost shifters para identificar α (Armstrong, 2012) e aplicar instrumentos ótimos de Chamberlain para identificar σ . 1ª etapa simples (logit linear + chute para σ) é suficiente.

Conclusão (cont.) — Avisos Cautelares

Avanços computacionais só mostram todo o potencial com instrumentos ótimos:

- Com z^4 : MPEC é $\approx 10\times$ mais rápido que NFP (vs. $1,75\times$ com z^1)
- Sparse Grid mais rápida e precisa que pMC *apenas* com instrumentos ótimos

Limitações e avisos:

- Resultados assumem ξ_{jt} não correlacionado com características de *todos* os produtos — se violado, instrumentos ótimos requerem modificação (Crawford, 2011; Akerberg e Crawford, 2009)
- Características dos produtos tratadas como exógenas e não correlacionadas entre produtos
- Modelo bem especificado (distribuição normal para ν) — validade em dados reais é agenda de pesquisa aberta

Obrigado

Obrigado!