

Some Tests of Specification for Panel Data

Monte Carlo Evidence and an Application to Employment Equations

Rafael Pereira Oliveira

Faculdade de Economia, Administração e Contabilidade (FEA-USP)

2026

Sumário

- 1 Contexto e motivação
- 2 O modelo e as restrições de momento
- 3 O estimador GMM
- 4 Extensões do modelo base
- 5 Testes de especificação
- 6 Evidência de Monte Carlo
- 7 Aplicação empírica: equações de emprego
- 8 Síntese e legado

1. Contexto e Motivação

O artigo ataca um problema clássico e muito prático em econometria de dados em painel: como estimar modelos dinâmicos, que contêm a variável dependente defasada como regressor, quando os dados têm uma dimensão individual, empresas, indivíduos, países, com efeitos fixos não observáveis?

Para entender o problema, considere o modelo mais simples possível:

$$y_{it} = \alpha y_{i,t-1} + \eta_i + v_{it} \quad (1)$$

onde η_i é o efeito fixo individual, não observável, e v_{it} é o erro idiossincrático.

1. Contexto e Motivação

Há dois problemas clássicos aqui.

Problema 1 — Viés do OLS em níveis

$y_{i,t-1}$ é correlacionado com η_i por construção, pois todos os valores passados de y dependem de η_i . OLS produz um estimador viesado para cima.

Problema 2 — Viés do estimador Within, efeitos fixos

A solução padrão para efeito fixo é tomar desvios em relação à média temporal, *within transformation*, ou, equivalentemente, primeiras diferenças. Mas ao diferenciar, $\Delta y_{i,t-1}$ ainda é correlacionado com Δv_{it} , porque $v_{i,t-1}$ aparece em ambos. Isso produz um viés de magnitude $1/T$, que é relevante quando T é pequeno.

1. Contexto e Motivação

A solução já conhecida antes de Arellano e Bond era o estimador de Anderson e Hsiao (1981, 1982): tomar primeiras diferenças para eliminar η_i e usar $y_{i,t-2}$, em nível ou em diferença, como variável instrumental para $\Delta y_{i,t-1}$.

Esse instrumento é válido porque, sob a hipótese de que v_{it} não tem correlação serial, $y_{i,t-2}$ é correlacionado com $\Delta y_{i,t-1}$, mas não com Δv_{it} .

A contribuição central de Arellano e Bond é mostrar que Anderson e Hsiao usam apenas um instrumento por período, desperdiçando uma quantidade substancial de informação válida. O artigo propõe usar o conjunto completo de restrições de momento disponíveis e estimar o modelo por GMM de forma eficiente.

2. O Modelo e as Restrições de Momento

Após tomar primeiras diferenças, a equação, para o caso autoregressivo simples, é:

$$\Delta y_{it} = \alpha \Delta y_{i,t-1} + \Delta v_{it} \quad (2)$$

A hipótese fundamental é que v_{it} é serialmente não correlacionado:

$$E[v_{it} v_{is}] = 0 \quad \text{para } t \neq s \quad (3)$$

Sob essa hipótese, para cada equação no período t , todos os níveis de y defasados dois ou mais períodos são instrumentos válidos:

$$E[y_{i,t-s} \Delta v_{it}] = 0 \quad \text{para } s \geq 2 \quad (4)$$

2. O Modelo e as Restrições de Momento

Isso porque $y_{i,t-s}$, com $s \geq 2$, não é correlacionado com Δv_{it} quando os erros em nível são não correlacionados.

O número total de restrições de momento lineares disponíveis é:

$$\sum_{t=3}^T (t-2) = \frac{(T-1)(T-2)}{2} \quad (5)$$

Para $T = 10$, por exemplo, isso gera 36 restrições de momento, em contraste com as poucas usadas por Anderson e Hsiao.

2. O Modelo e as Restrições de Momento

A matriz de instrumentos para o indivíduo i tem estrutura bloco-diagonal:

$$Z_i = \begin{bmatrix} y_{i1} & 0 & 0 & \cdots & 0 \\ 0 & y_{i1} & y_{i2} & \cdots & 0 \\ 0 & 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & \cdots & y_{i,T-2} \end{bmatrix} \quad (6)$$

onde o bloco t -ésimo contém $y_{i1}, \dots, y_{i,t-2}$ como instrumentos para a equação em diferenças do período t .

3. O Estimador GMM

As restrições de momento podem ser escritas compactamente como:

$$E[Z_i' \Delta v_i] = 0 \quad (7)$$

onde Δv_i é o vetor de erros diferenciados.

O estimador GMM minimiza a forma quadrática:

$$\left(\sum_{i=1}^N Z_i' \Delta \hat{v}_i \right)' W_N \left(\sum_{i=1}^N Z_i' \Delta \hat{v}_i \right) \quad (8)$$

3. O Estimador GMM

Isso resulta na fórmula fechada:

$$\hat{\alpha} = \left[\left(\sum_i X_i' Z_i \right) W_N \left(\sum_i Z_i' X_i \right) \right]^{-1} \left[\left(\sum_i X_i' Z_i \right) W_N \left(\sum_i Z_i' y_i \right) \right] \quad (9)$$

Estimador de um passo (*one-step*)

A escolha padrão é $W_N = (\sum_i Z_i' H Z_i)^{-1}$, onde H é uma matriz com 2 na diagonal principal e -1 nas primeiras subdiagonais. Essa escolha é ótima se os erros são homoscedásticos e independentes no tempo.

3. O Estimador GMM

Estimador de dois passos (*two-step*)

Usa uma estimativa consistente da matriz de variância-covariância dos momentos como ponderação:

$$\hat{W}_N = \left(\sum_i Z_i' \hat{\Delta}_{v_i} \hat{\Delta}_{v_i}' Z_i \right)^{-1} \quad (10)$$

onde $\hat{\Delta}_{v_i}$ são os resíduos do estimador de um passo.

Esse é o estimador assintoticamente eficiente sob hipóteses gerais, heteroscedasticidade e correlação temporal arbitrária nos erros.

3. O Estimador GMM

A variância assintótica consistente para qualquer W_N é:

$$\widehat{\text{Var}}(\hat{\alpha}) = (X'ZWZ'X)^{-1} \left(X'ZW\hat{S}WZ'X \right) (X'ZWZ'X)^{-1} \quad (11)$$

onde $\hat{S}$ é a matriz estimada de covariâncias dos momentos.

4. Extensões do Modelo Base

4.1 Variáveis exógenas adicionais

O modelo se estende naturalmente para:

$$y_{it} = \alpha y_{i,t-1} + x'_{it}\beta + \eta_i + v_{it} \quad (12)$$

A estrutura dos instrumentos depende da relação das variáveis com os erros.

- Se x_{it} é **predeterminada**, correlacionada com erros passados mas não futuros, apenas valores defasados são instrumentos válidos para a equação do período t .
- Se x_{it} é **estritamente exógena**, $E[x_{it} v_{is}] = 0$ para todos s, t , todos os valores da variável, passados, presentes e futuros, são instrumentos válidos.

4. Extensões do Modelo Base

4.2 Painéis não balanceados

O artigo trata explicitamente o caso de painéis não balanceados, número de períodos diferente por indivíduo, muito comum com dados de firmas.

A adaptação é simples: para indivíduos com menos períodos, deleta-se as linhas correspondentes da matriz Z_i e substitui-se por zeros os valores ausentes. O estimador de dois passos mantém a mesma forma.

5. Testes de Especificação

Esta é a segunda contribuição central do artigo. O estimador GMM é consistente sob a hipótese de que v_{it} não tem correlação serial. Portanto, é essencial testar essa hipótese após a estimação.

Os autores propõem e comparam três testes.

5.1 Teste de Correlação Serial (m_2)

Como a estimação ocorre na equação em primeiras diferenças, os erros diferenciados têm, por construção, correlação de primeira ordem negativa mesmo que v_{it} seja ruído branco. O que invalida os instrumentos é a correlação serial de segunda ordem em Δv_{it} , que ocorre se e somente se v_{it} em nível tem correlação serial.

5. Testes de Especificação

O teste testa H_0 e segue distribuição assintoticamente normal:

$$m_2 = \frac{\sum_i \hat{\Delta}v_{it} \hat{\Delta}v_{i,t-2}}{\sqrt{\widehat{\text{Var}}\left(\sum_i \hat{\Delta}v_{it} \hat{\Delta}v_{i,t-2}\right)}} \stackrel{a}{\sim} N(0, 1) \quad (13)$$

onde $\hat{\Delta}v_{i,t-2}$ é o vetor de resíduos defasados em dois períodos. A expressão de m_2 , equação 9 do artigo, corrige para a estimação de α . Os autores também apresentam um m_1 , que testa correlação serial de primeira ordem, útil para diagnóstico adicional.

5. Testes de Especificação

5.2 Teste de Sargan (sobre-identificação)

Com restrições de momento disponíveis, o modelo é sobre-identificado. O teste de Sargan testa a validade conjunta de todos os instrumentos:

$$S = \left(\sum_i Z_i' \hat{\Delta} v_i \right)' \hat{W}_N \left(\sum_i Z_i' \hat{\Delta} v_i \right) \stackrel{a}{\sim} \chi_{q-p}^2 \quad (14)$$

onde q é o número de colunas em Z e p é o número de parâmetros.

5. Testes de Especificação

Importante: o teste de Sargan robusto requer os resíduos do estimador de dois passos; a versão de um passo só tem distribuição qui-quadrado sob erros i.i.d.

Sargan diferença (*difference-Sargan*)

Uma variante que compara dois conjuntos aninhados de instrumentos. Se $Z_1 \subset Z_2$, instrumentos válidos sob H_0 , a diferença entre os critérios GMM possui distribuição qui-quadrado e testa se os instrumentos adicionais em Z_2 são válidos, o que equivale a testar se os erros em nível são MA(0) versus MA(1).

5. Testes de Especificação

5.3 Teste de Hausman

Baseia-se na diferença entre o estimador GMM completo e o estimador que usa apenas os instrumentos válidos sob erros MA(1):

$$H = (\hat{\theta}_1 - \hat{\theta}_2)' \left[\widehat{\text{Var}}(\hat{\theta}_1) - \widehat{\text{Var}}(\hat{\theta}_2) \right]^{-1} (\hat{\theta}_1 - \hat{\theta}_2) \quad (15)$$

onde $\hat{\theta}_1$ é o estimador mais eficiente sob a hipótese nula.

6. Evidência de Monte Carlo

Os autores realizam simulações com $N = 500$, $T = 4, 6, 8$ e 100 replicações, gerando dados a partir de:

$$y_{it} = \alpha y_{i,t-1} + \eta_i + v_{it} \quad (16)$$

Os principais resultados são:

Sobre os estimadores (Tabela 1)

- O GMM, um e dois passos, apresenta viés pequeno em amostras finitas, da ordem de 2 a 3%, para diferentes valores de α .
- OLS em nível tem viés fortemente positivo, correlação entre $y_{i,t-1}$ e η_i .
- *Within-groups* tem viés negativo, com magnitude inversamente proporcional a T .

6. Evidência de Monte Carlo

- O estimador Anderson-Hsiao pode apresentar problemas de identificação, quando $y_{i,t-2}$ e $\Delta y_{i,t-1}$ se tornam não correlacionados para certos valores de α , e tem variância muito maior do que o GMM, de 3 a 5 vezes para os valores simulados.
- O desvio padrão assintótico do estimador de dois passos apresenta viés de cerca de 20% para baixo em amostras finitas, o que é uma advertência prática importante.

6. Evidência de Monte Carlo

Sobre os testes de tamanho (Tabela 2, hipótese nula verdadeira)

- Os três testes apresentam tamanho empírico próximo do nominal, as distribuições assintóticas são boa aproximação mesmo com $N = 500$.
- O Sargan de dois passos também se comporta bem.
- O Hausman de dois passos tende a rejeitar excessivamente.

Sobre o poder dos testes (Tabela 3, hipótese alternativa com correlação MA(1))

- O m_2 é o teste mais poderoso: com correlação de 0,2 nos erros, rejeita em mais de 50% das vezes; com correlação de 0,3, rejeita em 95%.
- O Hausman tem poder consideravelmente menor.

6. Evidência de Monte Carlo

Em presença de heteroscedasticidade, os testes não robustos, baseados em estimador de um passo sem correção, rejeitam excessivamente, enquanto o m_2 robusto e o Sargan diferença de dois passos mantêm o tamanho nominal.

7. Aplicação Empírica: Equações de Emprego

Os autores estimam um modelo dinâmico de demanda por trabalho para 140 empresas industriais britânicas, painel não balanceado, 1979–1984:

$$n_{it} = \alpha n_{i,t-1} + \beta_1 w_{it} + \beta_2 k_{it} + \beta_3 y_{it} + \tau_t + \eta_i + v_{it} \quad (17)$$

onde n_{it} é o log do emprego, w_{it} inclui salário real, k_{it} estoque de capital e y_{it} *output* setorial, τ_t são efeitos de tempo comuns.

7. Aplicação Empírica: Equações de Emprego

As principais conclusões práticas são:

- O GMM produz estimativas bem determinadas com sinais esperados, salário negativo, capital e demanda positivos.
- Os coeficientes na defasada dependente ficam entre as estimativas do OLS, viesado para cima, e do *within-groups*, viesado para baixo, o que é consistente com a teoria.
- Os testes robustos não rejeitam a hipótese de erros serialmente não correlacionados, validando a estratégia de instrumentação.

7. Aplicação Empírica: Equações de Emprego

- O estimador Anderson-Hsiao, com instrumento único, produz coeficientes muito pouco precisos, confirmando o ganho de eficiência do GMM na prática.
- Quando salários e capital são tratados como predeterminados, em vez de estritamente exógenos, os resultados se alteram, as estatísticas de Hausman sugerem que a hipótese de exogeneidade estrita pode ser rejeitada para essas variáveis.
- As estimativas do erro padrão de dois passos são sistematicamente inferiores às de um passo, mas os resultados de Monte Carlo sugerem cautela, pois aquelas têm viés para baixo em amostras moderadas.

8. Síntese e Legado

A contribuição do artigo se estrutura em três pilares interdependentes.

Pilar 1 — Eficiência

O estimador GMM de Arellano-Bond explora o conjunto completo de restrições de momento lineares disponíveis, sendo assintoticamente mais eficiente do que Anderson-Hsiao e, de forma geral, do que qualquer estimador IV com conjunto de instrumentos reduzido.

Pilar 2 — Robustez

O estimador de dois passos com variância corrigida é robusto à heteroscedasticidade e correlação serial de forma arbitrária nos erros, propriedade que os estimadores anteriores não garantiam.

8. Síntese e Legado

Pilar 3 — Diagnóstico

O teste m_2 proposto fornece uma forma direta e bem calibrada de verificar a hipótese central de identificação, algo ausente na literatura anterior.

Uma limitação importante, reconhecida pelos próprios autores, é o viés de baixo nos erros padrão do estimador de dois passos em amostras finitas, problema que motivou trabalhos posteriores, como Windmeijer (2005), que propôs uma correção específica.

Adicionalmente, quando T cresce, a proliferação de instrumentos pode comprometer a validade do teste de Sargan e introduzir viés no próprio estimador, o que levou ao desenvolvimento do estimador “System GMM” por Blundell e Bond (1998).

Obrigado

Obrigado!