

Swapping the Nested Fixed Point Algorithm

Aguirregabiria e Mira (2002)

Rafael Pereira Oliveira

Faculdade de Economia, Administração e Contabilidade (FEA-USP)

2002

Sumário

- 1 Motivação: NFXP, CCP e o Dilema Eficiência-Velocidade
- 2 Modelo de Decisão Markoviana Discreta
- 3 Operador de Iteração de Política e Propriedade Zero-Jacobiana
- 4 Algoritmo NPL e Equivalência com NFXP
- 5 Estimadores K-Estágio de Iteração de Política
- 6 Resultados: Modelo de Rust e Monte Carlo
- 7 Conclusão e Legado

1. Motivação: NFXP, CCP e o Dilema Eficiência-Velocidade

Dois extremos na literatura DDC:

- **NFXP** (Rust 1987): resolve PD completo a cada avaliação de $\mathcal{L}(\theta)$ — eficiente, mas computacionalmente caro
- **CCP** (Hotz-Miller 1993): inverte CCPs não-paramétricas para obter funções valor sem resolver PD — rápido, reputadamente ineficiente

Contribuição deste paper:

- Um CCP estimador bem construído é **assintoticamente equivalente** ao MLE
- Propõe família de estimadores K -PI que vai de CCP ($K = 1$) ao MLE ($K \rightarrow \infty$)
- Todos assintoticamente equivalentes; trade-off é apenas em **amostras finitas**
- Algoritmo NPL: 5 a 15 vezes mais rápido que NFXP no modelo de Rust

2. Modelo de Decisão Markoviana Discreta

Pressupostos centrais:

- **(A1) Aditividade:** $u(s, a) = u(x, a) + \varepsilon(a)$
- **(A2) Independência Condicional:** $p(x', \varepsilon' | x, a, \varepsilon) = g(\varepsilon' | x') f(x' | x, a)$

Equação de Bellman suavizada:

$$V_\sigma(x) = \int \max_a [u(x, a) + \varepsilon(a) + \beta \sum_{x'} V_\sigma(x') f(x' | x, a)] g(d\varepsilon | x) \quad (1)$$

CCPs e representação de Hotz-Miller:

$$V_\sigma = \varphi(P) = (I_M - \beta F^u(P))^{-1} \sum_a P(a) \odot [u(a) + e(a, P)] \quad (2)$$

- $F^u(P) = \sum_a P(a) \odot F(a)$: transição incondicional induzida por P
- Para extreme value: $e(a, P) = \gamma - \ln P(a)$ (forma fechada)
- **Invertibilidade de Hotz-Miller:** $P \mapsto \tilde{v}$ é bijeção $\Rightarrow V_\sigma = \varphi(P)$

3. Operador de Iteração de Política e Propriedade Zero-Jacobiana

Operador de iteração de política Ψ :

$$P = \Psi(P) \equiv \Lambda(\varphi(P)) \quad (3)$$

$\varphi(P)$: avaliação de política (CCPs $\rightarrow$ funções valor); $\Lambda(V)$: melhoria de política (funções valor $\rightarrow$ CCPs)

Proposição 1: Ψ tem único ponto fixo $\bar{P}$; sequência $P^K = \Psi(P^{K-1})$ converge para $\bar{P}$

Proposição 2 — Zero-Jacobiana (chave do paper):

$$\frac{\partial \Psi(\bar{P})}{\partial P} = 0 \quad (4)$$

Implicações:

- Matriz de pseudo-informação é bloco-diagonal em θ e P^* (parâmetros de perturbação)
- Score e pseudo-score **idênticos** nos verdadeiros parâmetros
- $\Rightarrow$ distribuição assintótica de todo K -PI é igual à do MLE

4. Algoritmo NPL e Equivalência com NFXP

Algoritmo NPL (inversão do aninhamento do NFXP):

Inicializar $P^0 \in [0, 1]^{MJ}$. Para $K \geq 1$:

$$\hat{\theta}^K = \arg \max_{\theta} \sum_i \ln \Psi_{(\theta, \hat{\theta}_f)}(P^{K-1})(a_i | x_i) \quad (\text{inner})$$

$$P^K = \Psi_{(\hat{\theta}^K, \hat{\theta}_f)}(P^{K-1}) \quad (\text{outer})$$

	NFXP	NPL
Inner loop	Resolve DP ($V = F(V)$)	Maximiza pseudo- $\mathcal{L}$
Outer loop	Maximiza $\mathcal{L}(\theta)$	Itera P até ponto fixo

Proposição 3: Se NPL converge, converge a uma raiz das equações de verossimilhança (mesmo resultado do NFXP). Decorre diretamente da Proposição 2.

5. Estimadores K-Estágio de Iteração de Política

K-PI Estimator (NPL inicializado com P^0 consistente):

$$\hat{\theta}^K = \arg \max_{\theta} \sum_i \ln \Psi_{(\theta, \hat{\theta}_f)}(P^{K-1})(a_i | x_i), \quad P^K = \Psi_{(\hat{\theta}^K, \hat{\theta}_f)}(P^{K-1}) \quad (5)$$

Família de estimadores: $K = 1$ (CCP de Hotz-Miller) $\rightarrow K \rightarrow \infty$ (MLE de Rust)

Proposição 4 — Resultado Principal:

$$\sqrt{n}(\hat{\theta}^K - \theta^*) \xrightarrow{d} \mathcal{N}(0, V^*) \quad (6)$$

V^* = variância assintótica do MLE parcial; independente de K e da precisão de P^0

Trade-off amostras finitas:

- $K = 1$: muito impreciso quando P^0 é ruidoso
- $K = 2$: captura quase toda a ganho do MLE com custo muito menor
- $K \geq 3$: ganhos marginais pequenos em relação ao MLE

6. Resultados: Velocidade e Precisão (Modelo de Rust)

Experimento 1 — Velocidade (NPL vs. NFXP):

- Iterações de política $\approx 100\%$ do tempo com > 200 estados
- Razão de iterações NFXP/NPL: $5,5\times$ (2 parâmetros); $9\times$ (4 parâmetros)
- Com valores iniciais ruins: razão chega a $10\text{--}15\times$

Experimento 2 — Monte Carlo (Tabela I, $n = 1.000$, 1.000 réplicas):

Estatística	1-PI	2-PI	3-PI
θ_0 : erro abs. médio (rel. MLE)	+4,7%	+1,6%	+0,3%
θ_0 : desvio-padrão (rel. MLE)	+6,8%	+1,2%	+0,3%
θ_1 : erro abs. médio (rel. MLE)	+18,7%	+1,5%	+0,2%
θ_1 : desvio-padrão (rel. MLE)	+11,0%	+1,3%	+0,2%

- 2-PI já captura quase todo o ganho do MLE; EP assintótico do 1-PI é viesado

7. Conclusão e Legado

Resultados:

- 1 CCP bem construído (usando $\varphi(P)$) é assintoticamente equivalente ao MLE — quebrando a sabedoria convencional de ineficiência do CCP
- 2 Família K-PI unifica CCP e NFXP; o 2-PI oferece o melhor custo-benefício
- 3 NPL é 5–15× mais rápido que NFXP sem sacrifício assintótico

Limitações:

- Requer CCPs não-paramétricas consistentes — difícil com heterogeneidade não-observada time-invariant ou choques agregados
- Resultados para horizonte infinito com domínio discreto finito; extensões contínuas requerem métodos de aproximação

7. Conclusão e Legado

Legado:

- Base para Aguirregabiria e Mira (2007): extensão para *jogos* dinâmicos com múltiplos agentes
- NPL tornou-se o algoritmo padrão para estimação de DDC games na literatura de OI
- Estabelece a abordagem two-step como metodologia dominante em modelos estruturais dinâmicos

Obrigado

Obrigado!